Machine Learning Conceptos Importantes

Dr. Mauricio Toledo-Acosta

Diplomado Ciencia de Datos con Python

Machine Learning

Table of Contents

ROC-AUC Score

Cross Validation



ROC-AUC Score

ROC-AUC Score

La curva paramétrica ROC (Receiver Operating Characteristic) muestra los valores FPR y TPR en varios valores de umbral de probabilidad. El score AUC es el area bajo la curva ROC, es una medida de rendimiento para los problemas de clasificación que representa el grado o medida de separabilidad. Indica la capacidad del modelo para distinguir entre clases.

ROC-AUC Score

ROC-AUC Score

La curva paramétrica ROC (Receiver Operating Characteristic) muestra los valores FPR y TPR en varios valores de umbral de probabilidad. El score AUC es el area bajo la curva ROC, es una medida de rendimiento para los problemas de clasificación que representa el grado o medida de separabilidad. Indica la capacidad del modelo para distinguir entre clases.

$$\begin{aligned} \text{FPR} &= \frac{\text{FP}}{\text{TN} + \text{FP}} \\ \text{TPR} &= \frac{\text{TP}}{\text{TP} + \text{FN}} \end{aligned}$$

◆□▶ ◆□▶ ◆■▶ ◆■▶ ■ 900

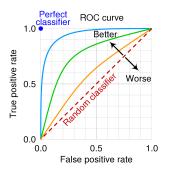
ROC-AUC Score

ROC-AUC Score

La curva paramétrica ROC (Receiver Operating Characteristic) muestra los valores FPR y TPR en varios valores de umbral de probabilidad. El score AUC es el area bajo la curva ROC, es una medida de rendimiento para los problemas de clasificación que representa el grado o medida de separabilidad. Indica la capacidad del modelo para distinguir entre clases.

$$\begin{aligned} \text{FPR} &= \frac{\text{FP}}{\text{TN} + \text{FP}} \\ \text{TPR} &= \frac{\text{TP}}{\text{TP} + \text{FN}} \longleftarrow \text{ Recall} \end{aligned}$$

◄□▶◀圖▶◀불▶◀불▶ 불 ∽Q♡



El valor ROC-AUC es un número $0 \le s \le 1$. Entre más grande es s, el clasificador es mejor.

- Si s = 1, el clasificador es perfecto.
- Si $s = \frac{1}{2}$, el clasificador es aleatorio.
- Si s = 0, el calsificador predice perfectamente las clases al revés.



Umbral: 0.5

y_test	y_pred	probabilidades
0	0	0.048
0	0	0.145
1	1	0.905
0	0	0.24
1	0	0.215
0	0	0.231
0	0	0.116
1	1	0.551
1	0	0.172
1	1	0.803

$$\begin{pmatrix} 5 & 0 \\ 2 & 3 \end{pmatrix}$$
, $TPR = 0.6$, $FPR = 0$



Umbral: 0.2

y_test	y_pred	probabilidades
0	0	0.048
0	0	0.145
1	1	0.905
0	1	0.24
1	1	0.215
0	1	0.231
0	0	0.116
1	1	0.551
1	0	0.172
1	1	0.803

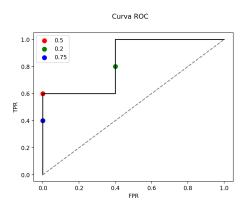
$$\left(\begin{array}{cc} 3 & 2 \\ 1 & 4 \end{array} \right), \quad TPR=0.8, \; FPR=0.4$$



Umbral: 0.75

$y_{-}test$	y_pred	probabilidades
0	0	0.048
0	0	0.145
1	1	0.905
0	0	0.24
1	0	0.215
0	0	0.231
0	0	0.116
1	0	0.551
1	0	0.172
1	1	0.803

$$\left(\begin{array}{cc} 5 & 0 \\ 3 & 2 \end{array} \right), \quad TPR=0.4, \; FPR=0$$



El área bajo la curva es 0.84.

Table of Contents

ROC-AUC Score

2 Cross Validation



Cross Validation

Validación Cruzada

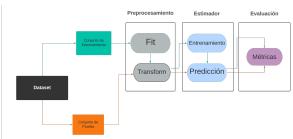
La validación cruzada es una técnica de validación de modelos para evaluar cómo se generalizarán los resultados de un análisis estadístico a un conjunto de datos independiente. La validación cruzada es un método de remuestreo que utiliza diferentes partes de los datos para probar y entrenar un modelo en diferentes iteraciones.

Es necesario tener una validación de la estabilidad de cualquier modelo de Machine Learning. Es decir, ¿qué tan bien podemos esperar que sea su rendimiento en datos que no ha visto?

• Validación: Evaluación del desempeño del modelo en los datos de entrenamiento.



- Validación: Evaluación del desempeño del modelo en los datos de entrenamiento.
- Conjunto de prueba: Reservar una parte del conjunto de datos para ser usada como conjunto de prueba.



• **K-Fold Cross Validation**: Los datos se dividen en k subconjuntos, una de las partes se usa como conjunto de prueba y las demás como entrenamiento. Se repite este método k veces, de forma que cada vez, uno de los k subconjuntos se utiliza como conjunto de prueba y los otros k-1 subconjuntos, como conjunto de entrenamiento. La estimación del error se promedia sobre las k pruebas para obtener la eficacia total de nuestro modelo.



 Stratified K-Fold Cross Validation: Variación de la validación cruzada K-fold normal, en lugar de que las divisiones sean completamente aleatorias, la proporción entre las clases objetivo es la misma en cada uno de los k subconjuntos que en el conjunto de datos completo.

