Reducción de dimensionalidad

Dr. Mauricio Toledo-Acosta
mauricio.toledo@unison.mx

Diplomado Ciencia de Datos con Python

Table of Contents

1 Introducción

2 PCA

3 t-SNE

Introducción

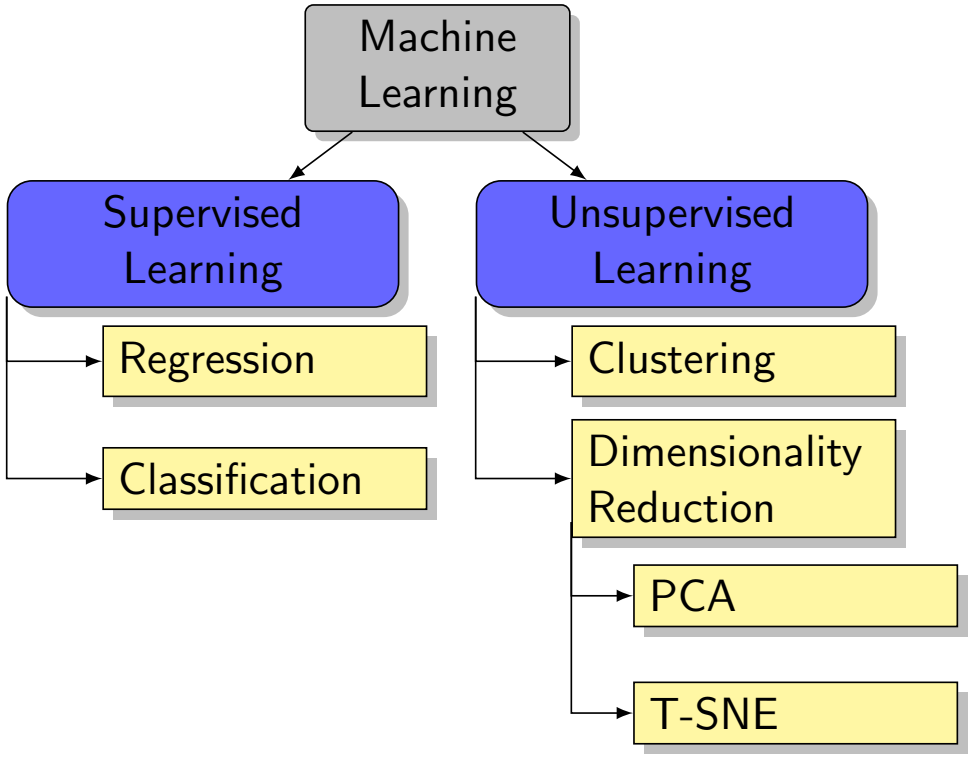

Reducción de dimensionalidad

Reducción de dimensionalidad

La reducción de la dimensionalidad es la transformación de los datos de un espacio de alta dimensión a un espacio de baja dimensión, de manera que la representación de baja dimensión conserve propiedades significativas de los datos originales.

Reducción de dimensionalidad

Reducción de dimensionalidad

La reducción de la dimensionalidad es la transformación de los datos de un espacio de alta dimensión a un espacio de baja dimensión, de manera que la representación de baja dimensión conserve propiedades significativas de los datos originales.

Reducción de dimensionalidad

Reducción de dimensionalidad

La reducción de la dimensionalidad es la transformación de los datos de un espacio de alta dimensión a un espacio de baja dimensión, de manera que la representación de baja dimensión conserve propiedades significativas de los datos originales.

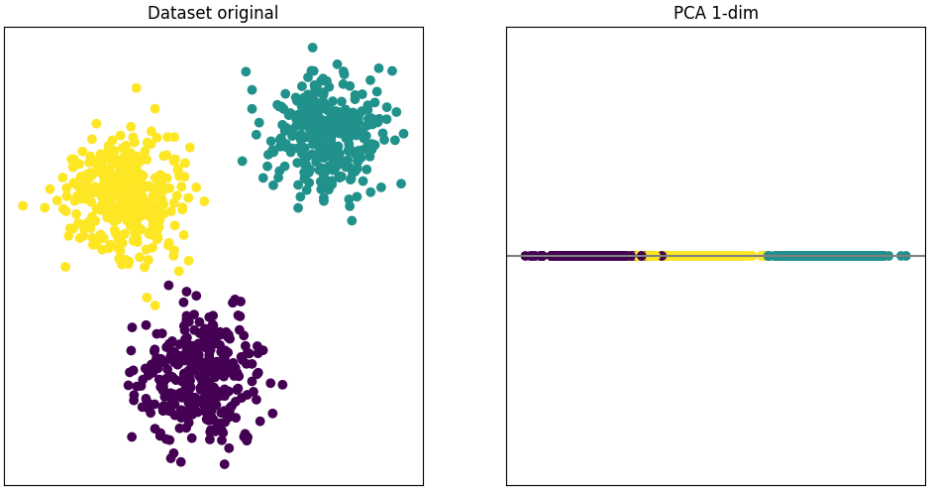

Reducción de dimensionalidad

Reducción de dimensionalidad

La reducción de la dimensionalidad es la transformación de los datos de un espacio de alta dimensión a un espacio de baja dimensión, de manera que la representación de baja dimensión conserve propiedades significativas de los datos originales.

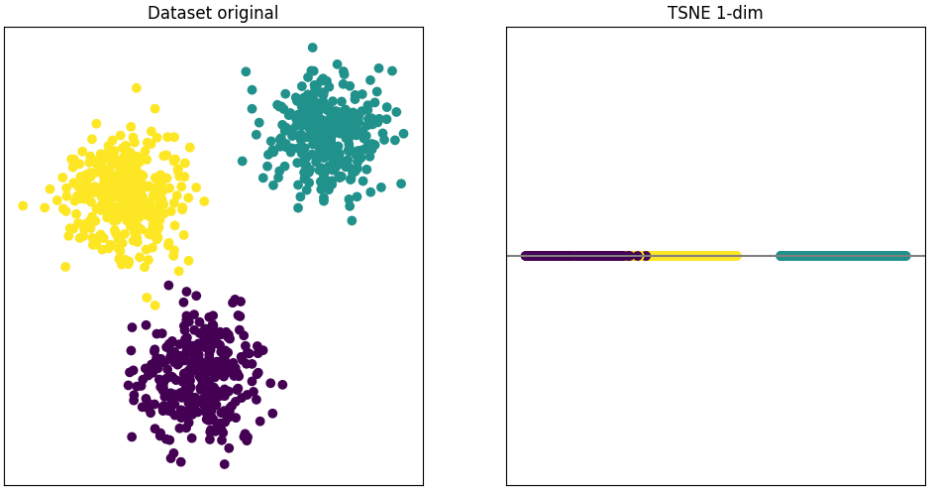

Clasificación de los Métodos

Desde un punto de vista matemático, se trata de transformar los datos de un espacio de alta dimensión a un espacio de baja dimensión.

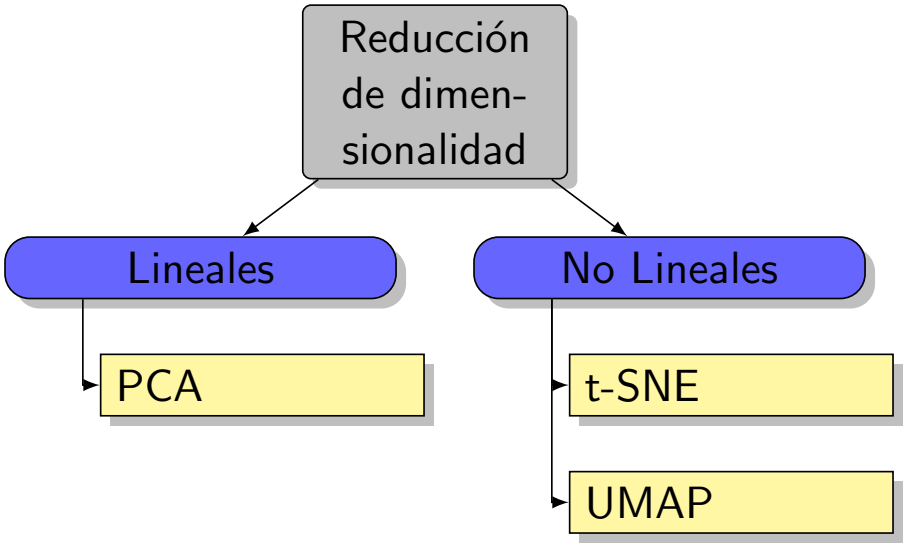

Clasificación de los Métodos

Desde un punto de vista computacional, se trata de reducir las features que definen a los datos para hacer más tratables las tareas del Machine Learning.

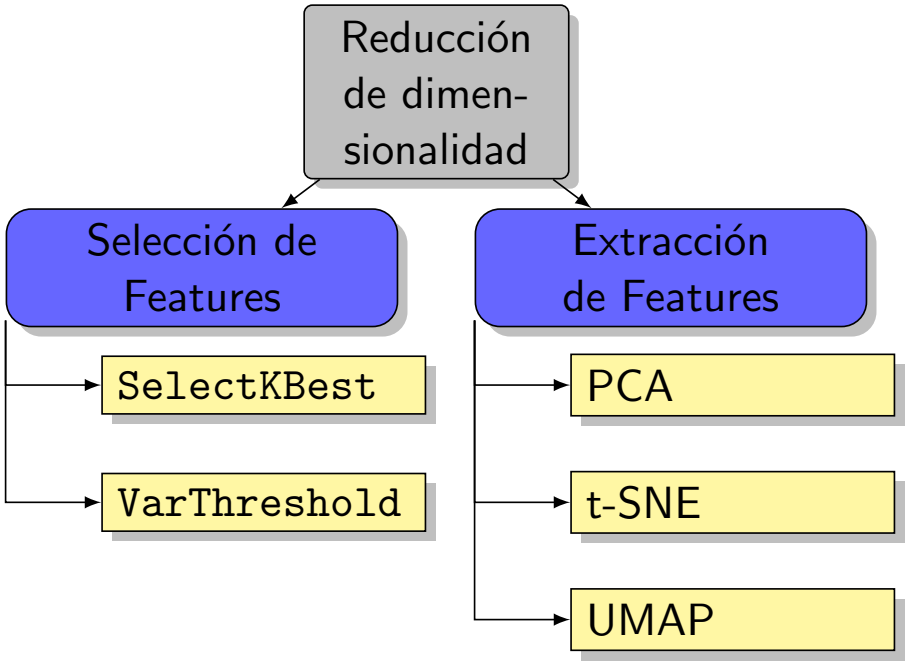

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.
- Extraer la información más importante de los datos.

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.
- Extraer la información más importante de los datos.
- Obtener features para fines de clasificación.

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.
- Extraer la información más importante de los datos.
- Obtener features para fines de clasificación.
- Menos espacio de almacenamiento.

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.
- Extraer la información más importante de los datos.
- Obtener features para fines de clasificación.
- Menos espacio de almacenamiento.
- Menos features requieren menos tiempo de cálculo (entrenamiento más rápido).

Utilidad

Ventajas

- Puede ser más fácil visualizar los datos.
- Extraer la información más importante de los datos.
- Obtener features para fines de clasificación.
- Menos espacio de almacenamiento.
- Menos features requieren menos tiempo de cálculo (entrenamiento más rápido).
- Menos features significan menos complejidad del módelo.

Feature Selection

Una forma de reducción de dimensionalidad es la selección de features.

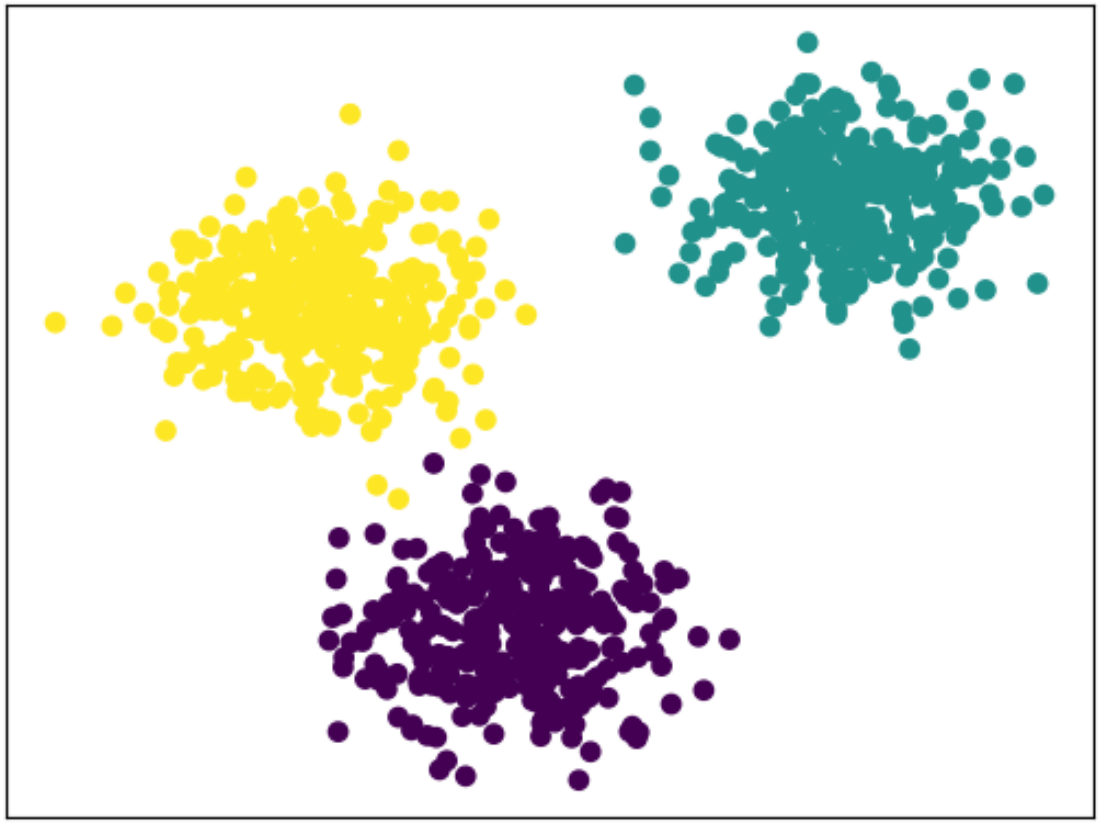

Feature Selection

Una forma de reducción de dimensionalidad es la selección de features.

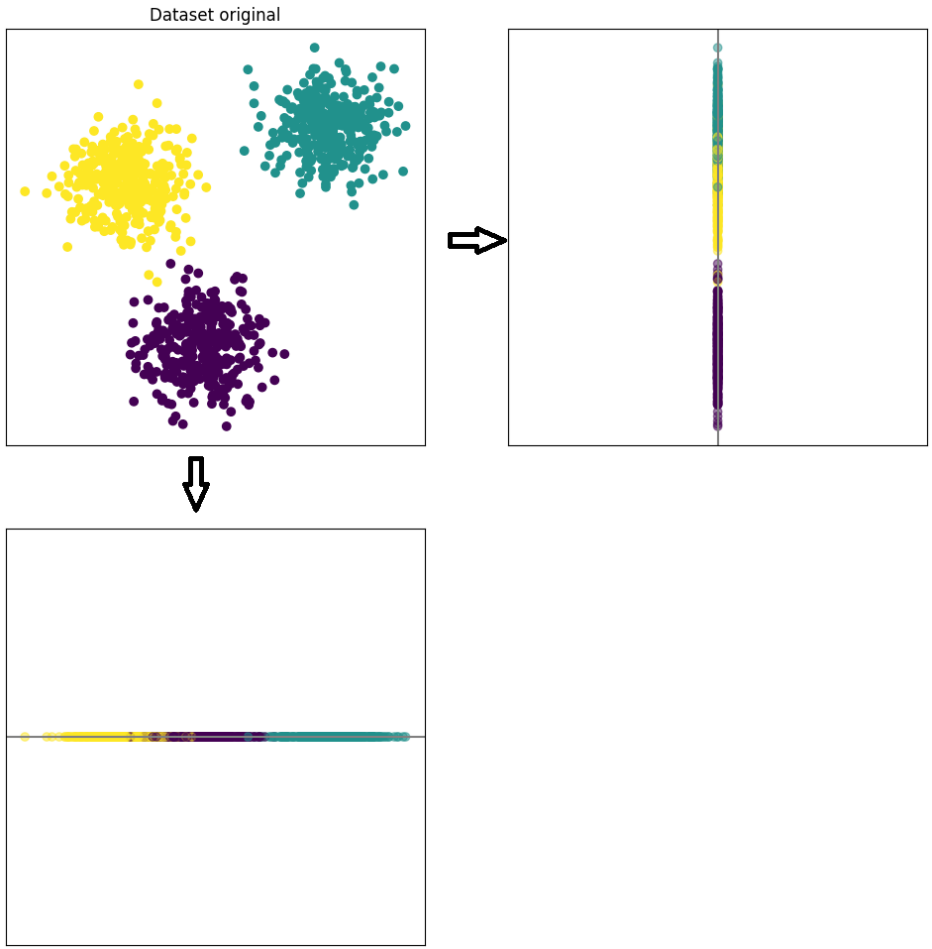

Table of Contents

1 Introducción

2 PCA

3 t-SNE

PCA

Introducido en 1901 por Karl Pearson (1857-1936).

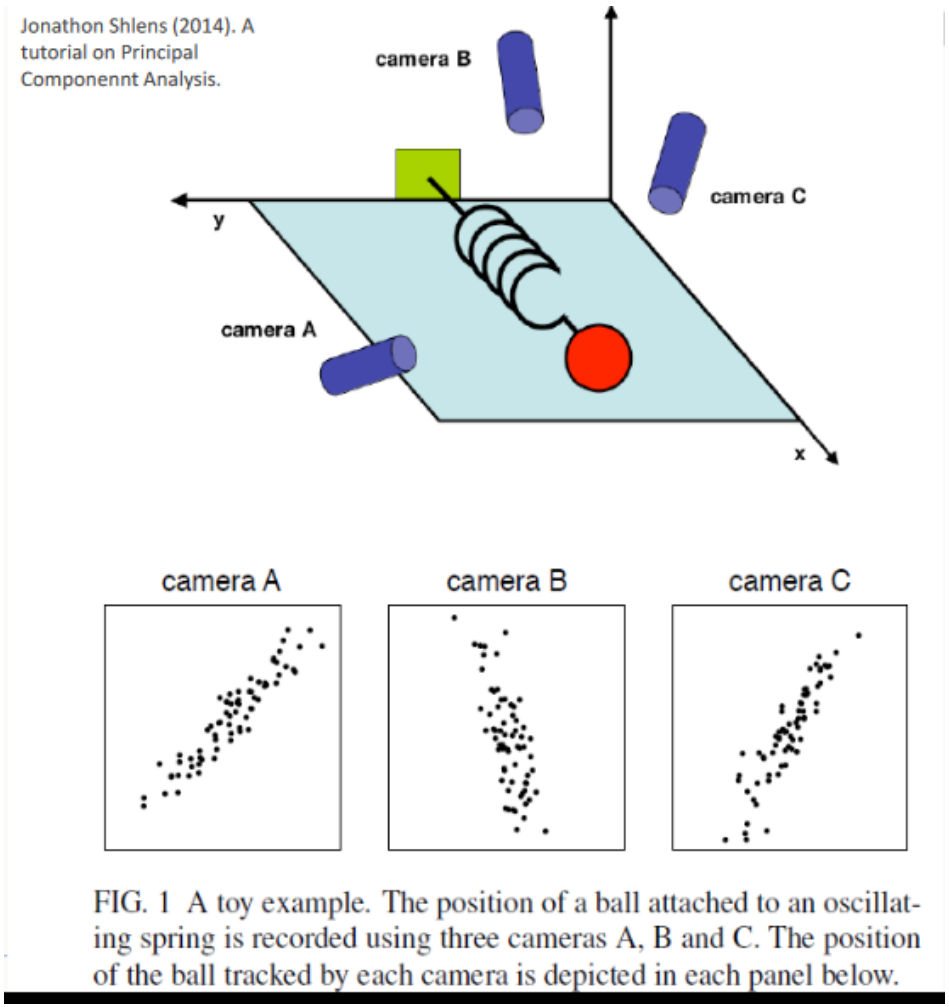

FIG. 1 A toy example. The position of a ball attached to an oscillating spring is recorded using three cameras A, B and C. The position of the ball tracked by each camera is depicted in each panel below.

PCA

PCA puede pensarse como el ajuste de un elipsoide D-dimensional al conjunto de datos, donde cada eje del elipsoide representa una componente principal. Si algún eje del elipsoide es pequeño, entonces la varianza a lo largo de ese eje también es pequeña.

PCA

PCA puede pensarse como el ajuste de un elipsoide D-dimensional al conjunto de datos, donde cada eje del elipsoide representa una componente principal. Si algún eje del elipsoide es pequeño, entonces la varianza a lo largo de ese eje también es pequeña.

PCA transforma los datos a un nuevo sistema de coordenadas de tal manera que la mayor varianza se sitúa en la primera coordenada, la segunda mayor varianza en la segunda coordenada, y así sucesivamente.

PCA

PCA puede pensarse como el ajuste de un elipsoide D-dimensional al conjunto de datos, donde cada eje del elipsoide representa una componente principal. Si algún eje del elipsoide es pequeño, entonces la varianza a lo largo de ese eje también es pequeña.

PCA transforma los datos a un nuevo sistema de coordenadas de tal manera que la mayor varianza se sitúa en la primera coordenada, la segunda mayor varianza en la segunda coordenada, y así sucesivamente.

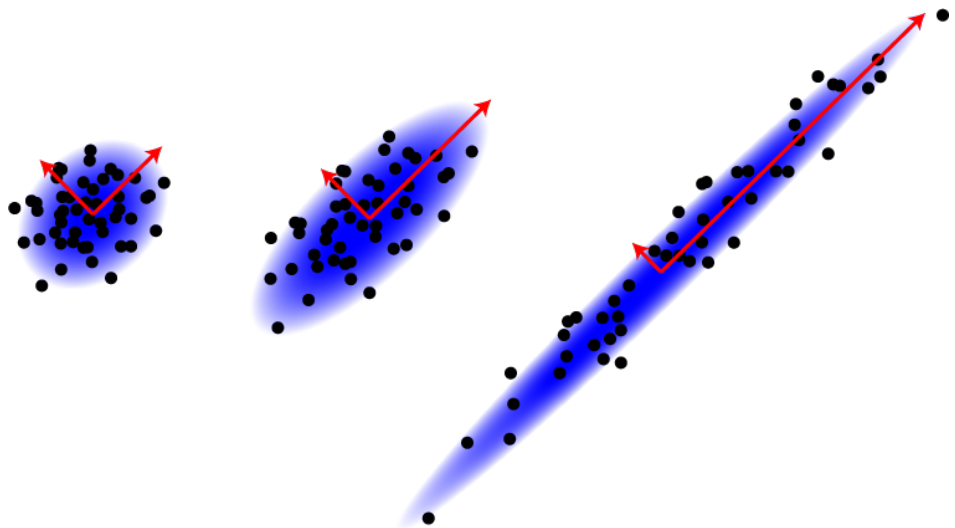

PCA

PCA puede pensarse como el ajuste de un elipsoide D-dimensional al conjunto de datos, donde cada eje del elipsoide representa una componente principal. Si algún eje del elipsoide es pequeño, entonces la varianza a lo largo de ese eje también es pequeña.

PCA transforma los datos a un nuevo sistema de coordenadas de tal manera que la mayor varianza se sitúa en la primera coordenada, la segunda mayor varianza en la segunda coordenada, y así sucesivamente.

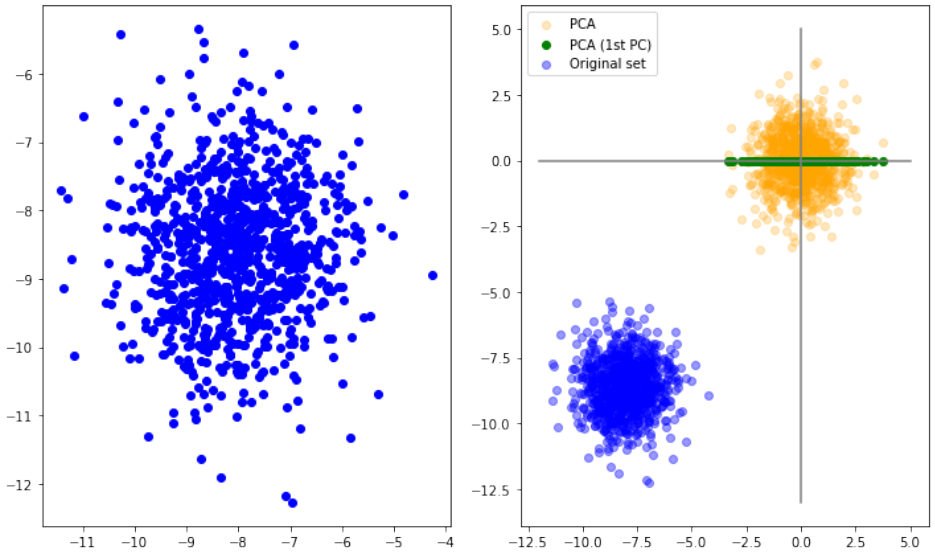

Cambios de Base

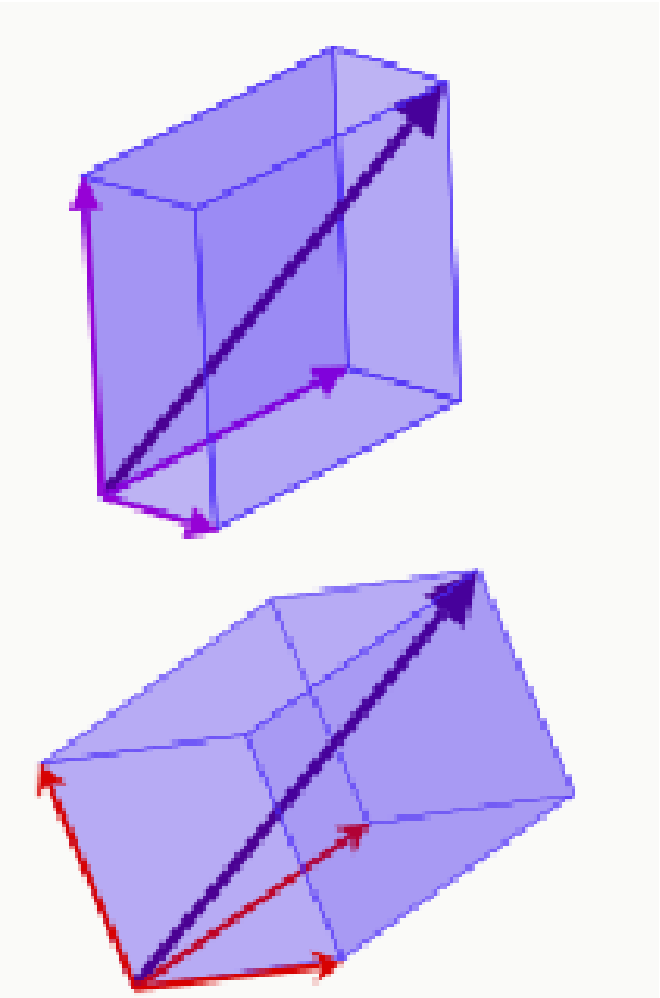

- Las coordenadas de un punto en son los coeficientes de los vectores canónicos unitarios

$$e_1 = (1, 0, ..., 0),$$
$$...$$
$$e_D = (0, 0, ..., 1).$$

- Todo punto puede ser expresado en una infinidad de bases.
- Para cambiar de base hay que multiplicar el vector por la matriz

$$\begin{pmatrix} v_1^{(1)} & \dots & v_1^{(D)} \\ & \dots & \\ v_D^{(1)} & \dots & v_D^{(D)} \end{pmatrix}$$

PCA

¿Cómo obtenemos la nueva base de coordenadas para PCA? Esta base de vectores deben ser las direcciones de máxima varianza, estas son las componentes principales.

PCA

¿Cómo obtenemos la nueva base de coordenadas para PCA? Esta base de vectores deben ser las direcciones de máxima varianza, estas son las componentes principales.

Consideremos la matriz de covarianza

$$C_X = \frac{1}{N} X \cdot X^T.$$

PCA

¿Cómo obtenemos la nueva base de coordenadas para PCA? Esta base de vectores deben ser las direcciones de máxima varianza, estas son las componentes principales.

Consideremos la matriz de covarianza

$$C_X = \frac{1}{N} X \cdot X^T.$$

- Los términos altos en la diagonal corresponden a una varianza alta.
- Los términos altos fuera de la diagonal corresponden a una redundancia alta.

Matriz de covarianza

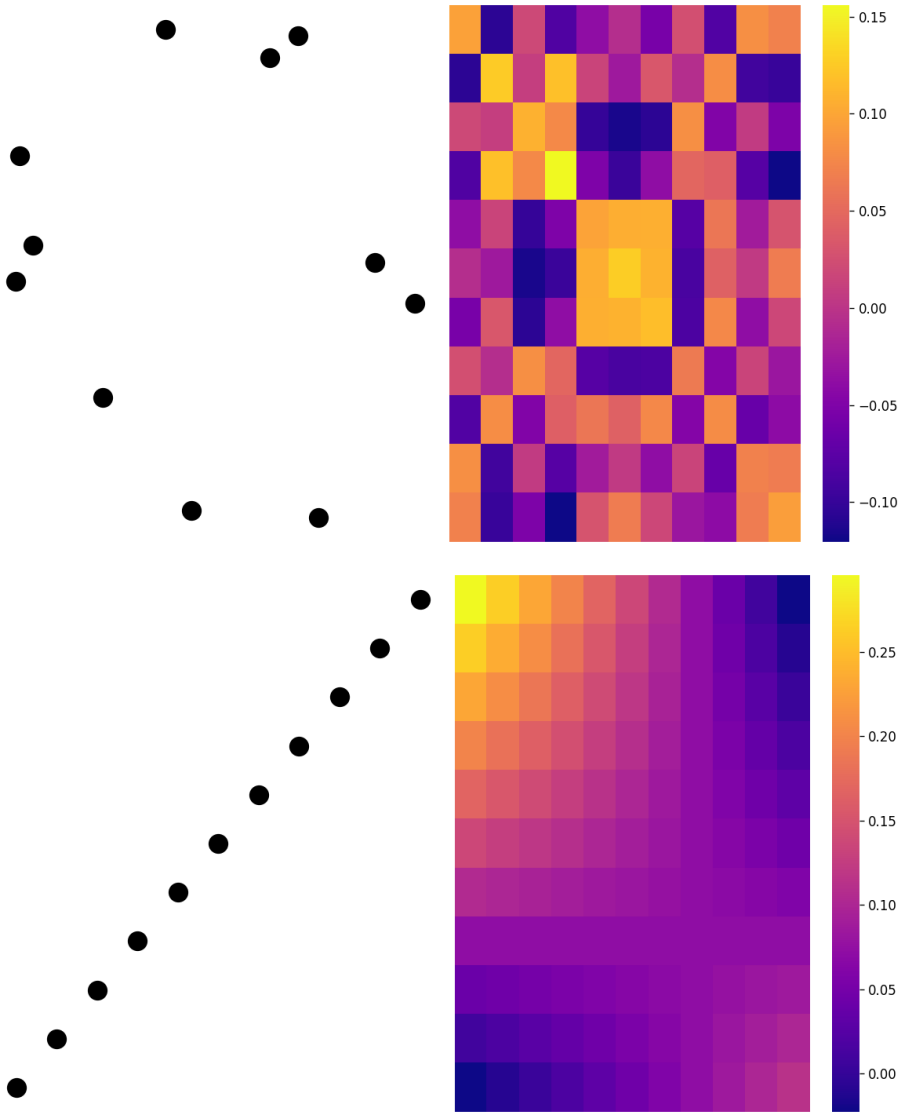

Matriz de Covarianza

De acuerdo con lo anterior, para nuestra matriz de covarianza C_X deseamos:

- Minimizar la redundancia, medida por la magnitud de la covarianza.
- Maximizar la varianza.

Matriz de Covarianza

De acuerdo con lo anterior, para nuestra matriz de covarianza C_X deseamos:

- Minimizar la redundancia, medida por la magnitud de la covarianza.
- Maximizar la varianza.

Esto, en términos de matrices, quiere decir Diagonalizar. Es decir, encontrar matrices P y D tales que

$$D = P \cdot C_X \cdot P^T$$

Matriz de Covarianza

De acuerdo con lo anterior, para nuestra matriz de covarianza C_X deseamos:

- Minimizar la redundancia, medida por la magnitud de la covarianza.
- Maximizar la varianza.

Esto, en términos de matrices, quiere decir Diagonalizar. Es decir, encontrar matrices P y D tales que

$$D = P \cdot C_X \cdot P^T$$

Esto se hace encontrando los eigenvector y eigenvalores de C_X.

Eigenvalores y Eigenvectores

Cada matriz M de tamaño $n \times n$ se puede ver como una transformación del espacio $\mathbb{R}^n$ en el espacio $\mathbb{R}^n$. Es decir, toma una punto $p \in \mathbb{R}^n$ y devuelve otro vector $M \cdot p \in \mathbb{R}^n$. ¿Cómo es este punto respecto al inicial?

Eigenvalores y Eigenvectores

Cada matriz M de tamaño $n \times n$ se puede ver como una transformación del espacio $\mathbb{R}^n$ en el espacio $\mathbb{R}^n$. Es decir, toma una punto $p \in \mathbb{R}^n$ y devuelve otro vector $M \cdot p \in \mathbb{R}^n$. ¿Cómo es este punto respecto al inicial?

Hay vectores especiales, dependiendo de M, que son transformados en un múltiplo de ellos mismos.

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$$A \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$A \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Eigenvalores y Eigenvectores

Cada matriz M de tamaño $n \times n$ se puede ver como una transformación del espacio $\mathbb{R}^n$ en el espacio $\mathbb{R}^n$. Es decir, toma una punto $p \in \mathbb{R}^n$ y devuelve otro vector $M \cdot p \in \mathbb{R}^n$. ¿Cómo es este punto respecto al inicial?

Hay vectores especiales, dependiendo de M, que son transformados en un múltiplo de ellos mismos.

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$$A \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \cdot \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$A \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

El proceso

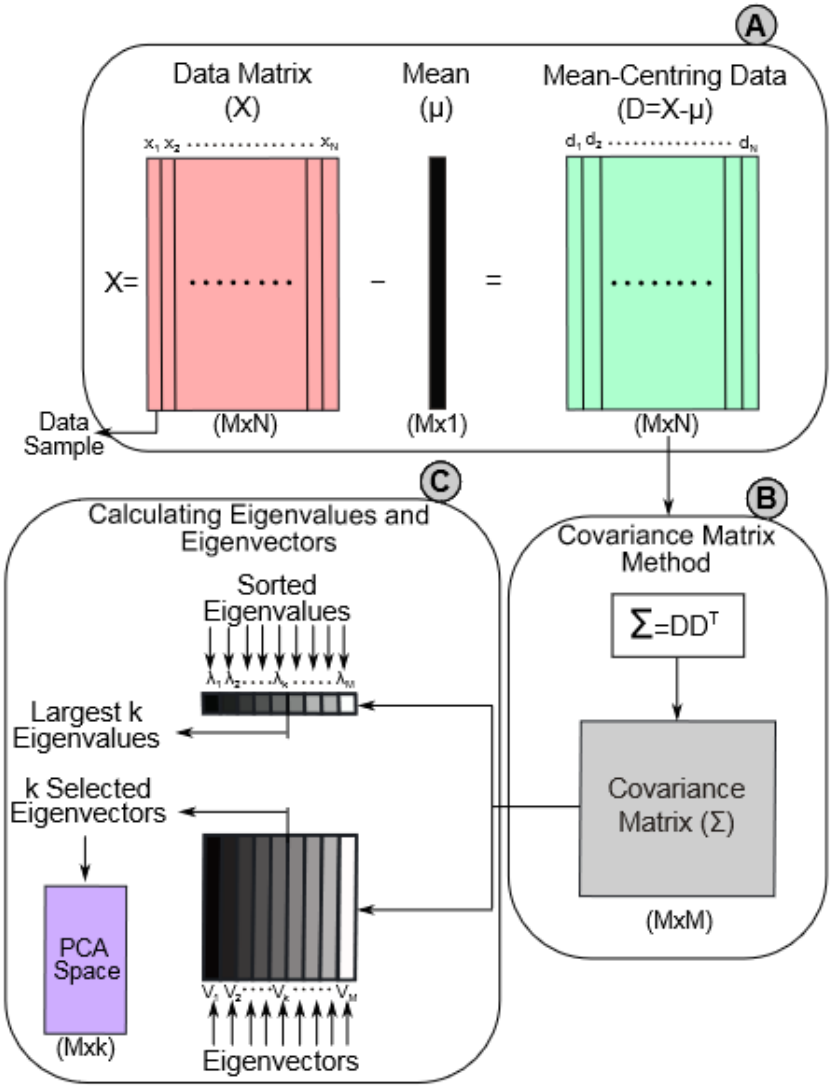
A
Data Matrix
(X)
Mean
(μ)
Mean-Centring Data
(D=X-μ)
X=
–
=
(MxN)
(Mx1)
(MxN)
Data
Sample
C
Calculating Eigenvalues and
Eigenvectors
Sorted
Eigenvalues
Largest k
Eigenvalues
k Selected
Eigenvectors
PCA
Space
(Mxk)
Eigenvectors
B
Covariance Matrix
Method
Σ=DDᵀ
Covariance
Matrix (Σ)
(MxM)

Conexiones entre la geometría y la estadística

- Promedio/Centroide = Media.
- Norma = Varianza.
- Ángulo entre vectores = Covarianza.

Ventajas y Desventajas

Ventajas

- Permite eliminar variables correlacionadas.
- Permite la visualización de datos.
- Puede ayudar a reducir el overfitting.

Ventajas y Desventajas

Ventajas

- Permite eliminar variables correlacionadas.
- Permite la visualización de datos.
- Puede ayudar a reducir el overfitting.

Desventajas

- Suele requiere de un escalamiento de datos antes.
- Se pierde información.
- Perdemos la interpretabilidad de las variables de entrada.

Table of Contents

1 Introducción

2 PCA

3 t-SNE

T-SNE

Desarrollado en 2008 por Laurens van der Maaten (FAIR) y Geoffery Hinton (University of Toronto). Significa t-distributed Stochastic Neighbor Embedding.

T-SNE

Desarrollado en 2008 por Laurens van der Maaten (FAIR) y Geoffery Hinton (University of Toronto). Significa t-distributed Stochastic Neighbor Embedding.

T-SNE modela cada objeto de alta dimensión mediante un punto bidimensional o tridimensional de tal forma que los objetos similares se modelan mediante puntos cercanos y los objetos no similares se modelan mediante puntos distantes con una alta probabilidad.

T-SNE: El proceso

1. Construir una distribución de probabilidad sobre pares de objetos en alta dimensión de tal manera que a los objetos similares se les asigna una probabilidad más alta mientras que a los puntos disímiles se les asigna una probabilidad más baja.
2. Definir una distribución de probabilidad similar sobre los puntos del mapa de baja dimensión, y minimiza la divergencia de Kullback-Leibler entre las dos distribuciones con respecto a las ubicaciones de los puntos en el mapa.

El proceso: Versión 1

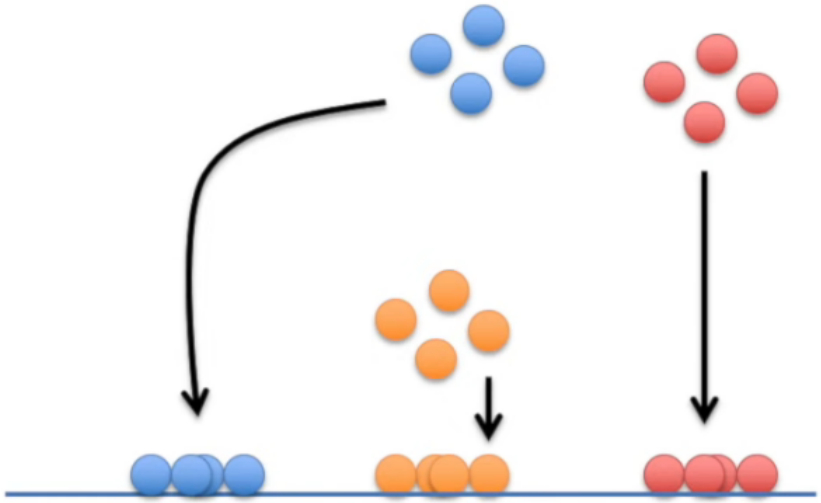

El proceso: Versión 1

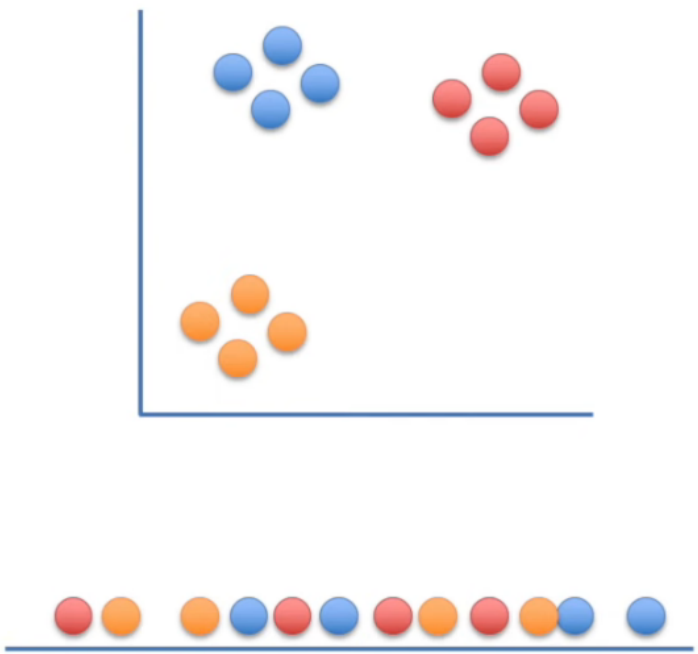

El proceso: Versión 1

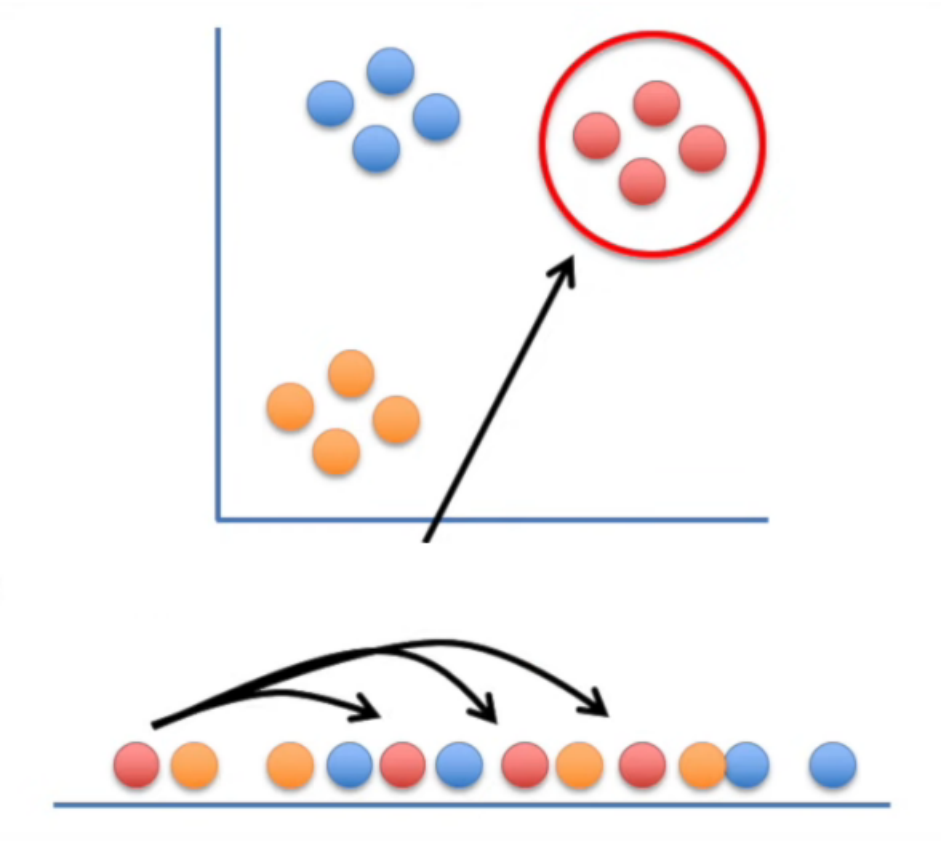

El proceso: Versión 1

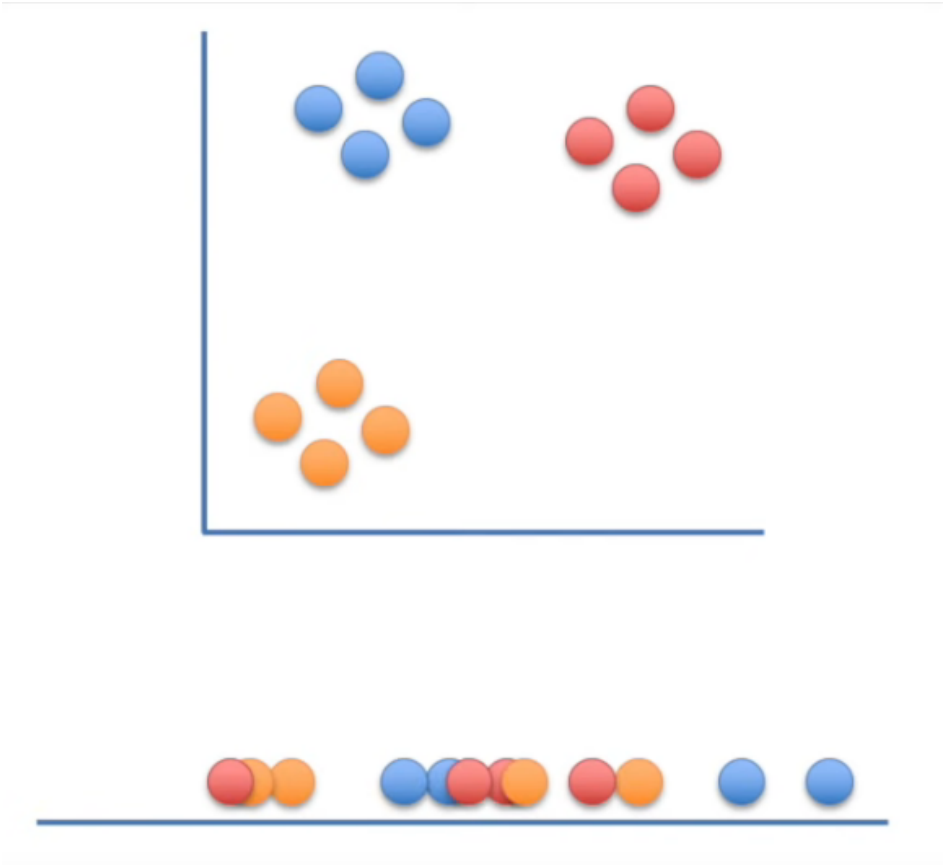

El proceso: Versión 1

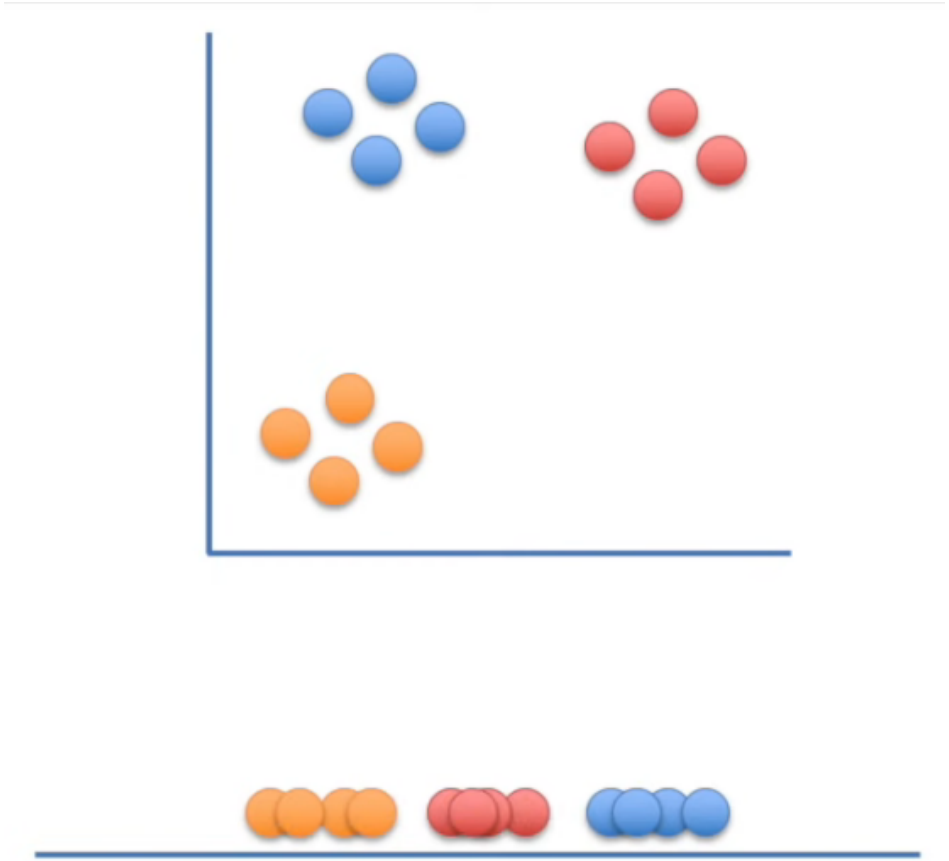

El proceso: Versión 2

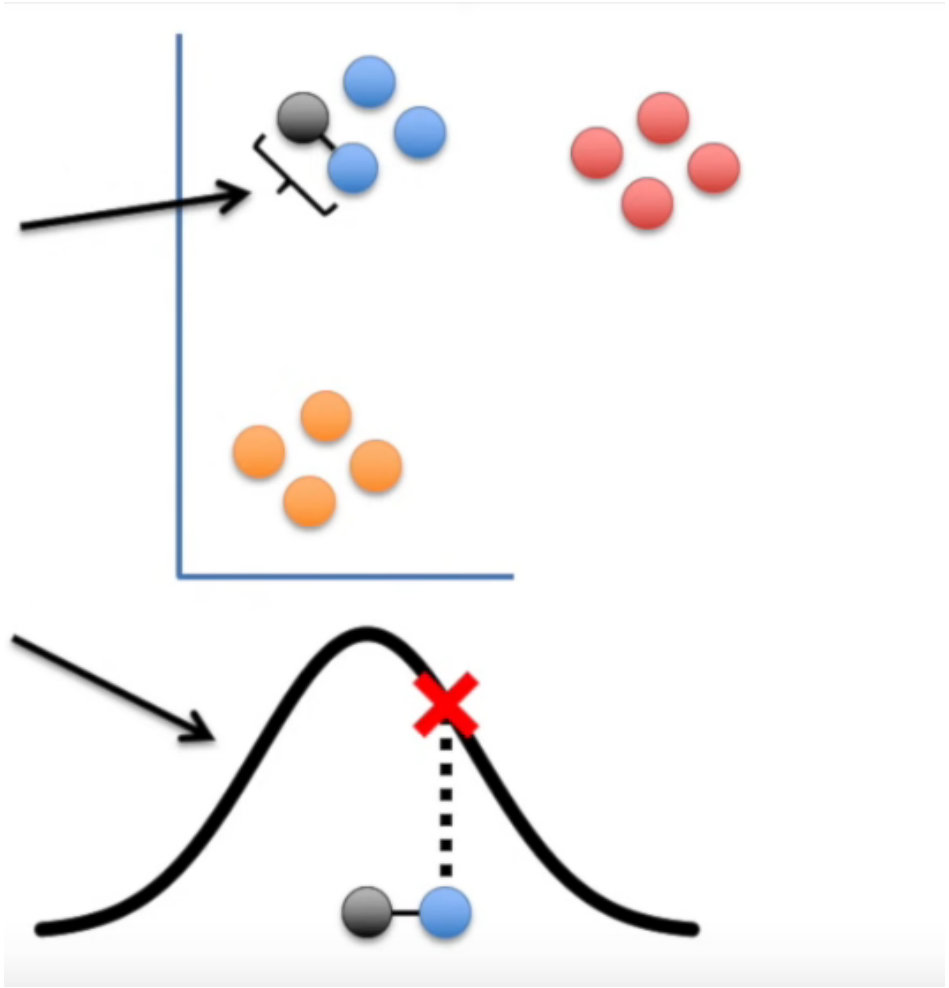

El proceso: Versión 2

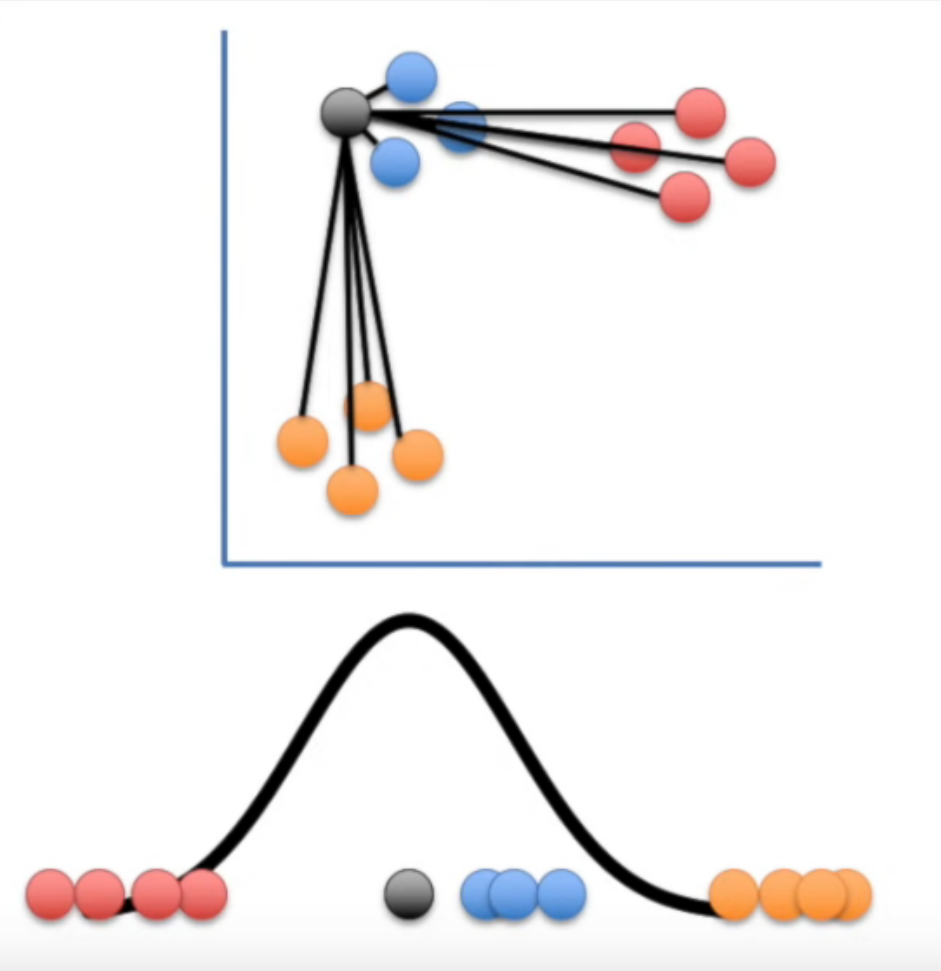

El proceso: Versión 2

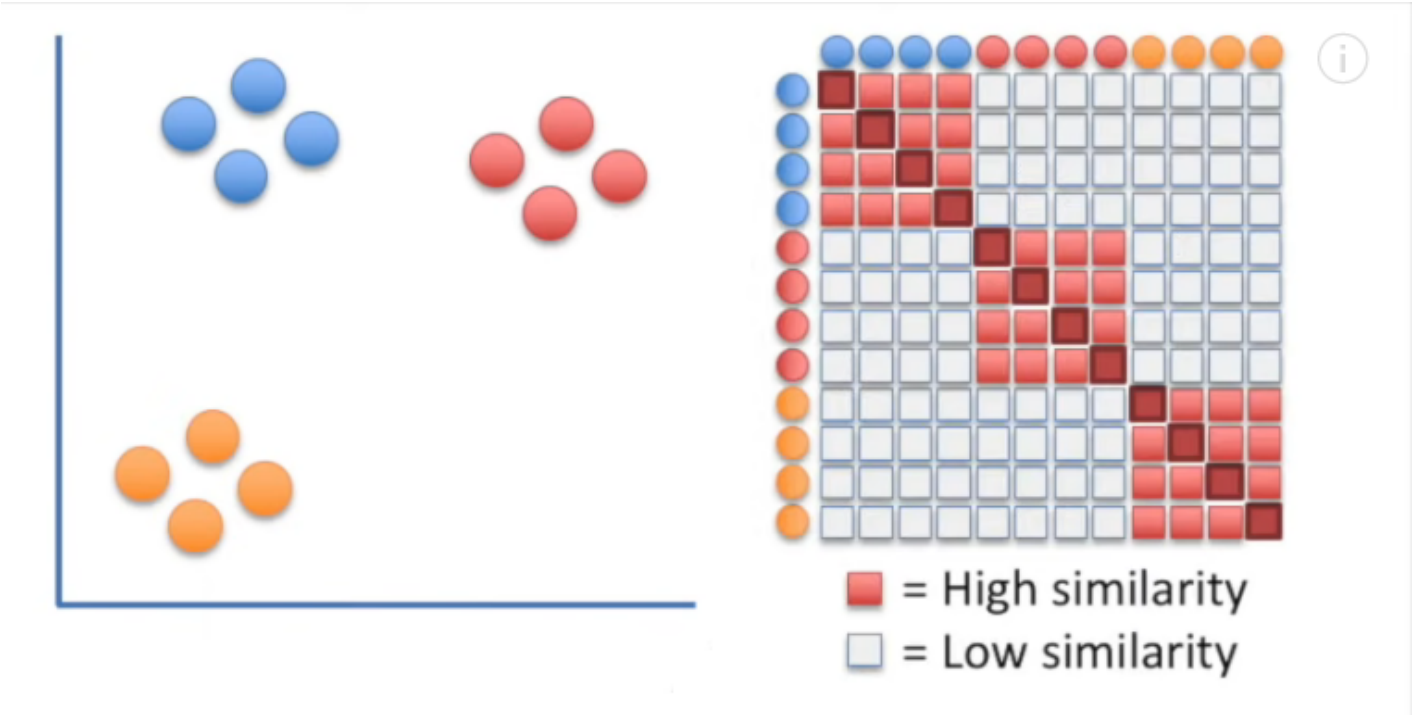

El proceso: Versión 2

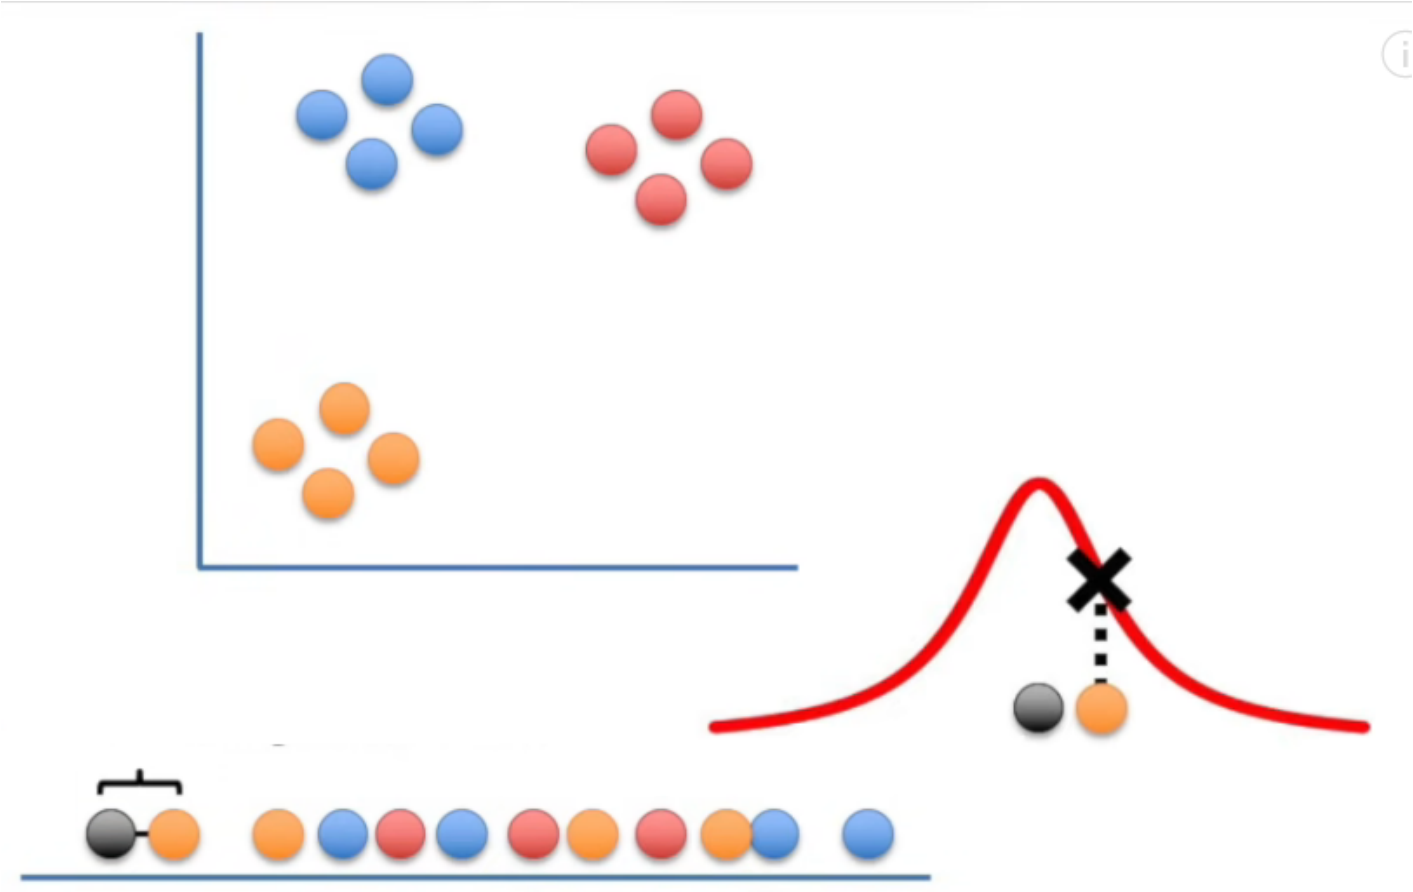

El proceso: Versión 2

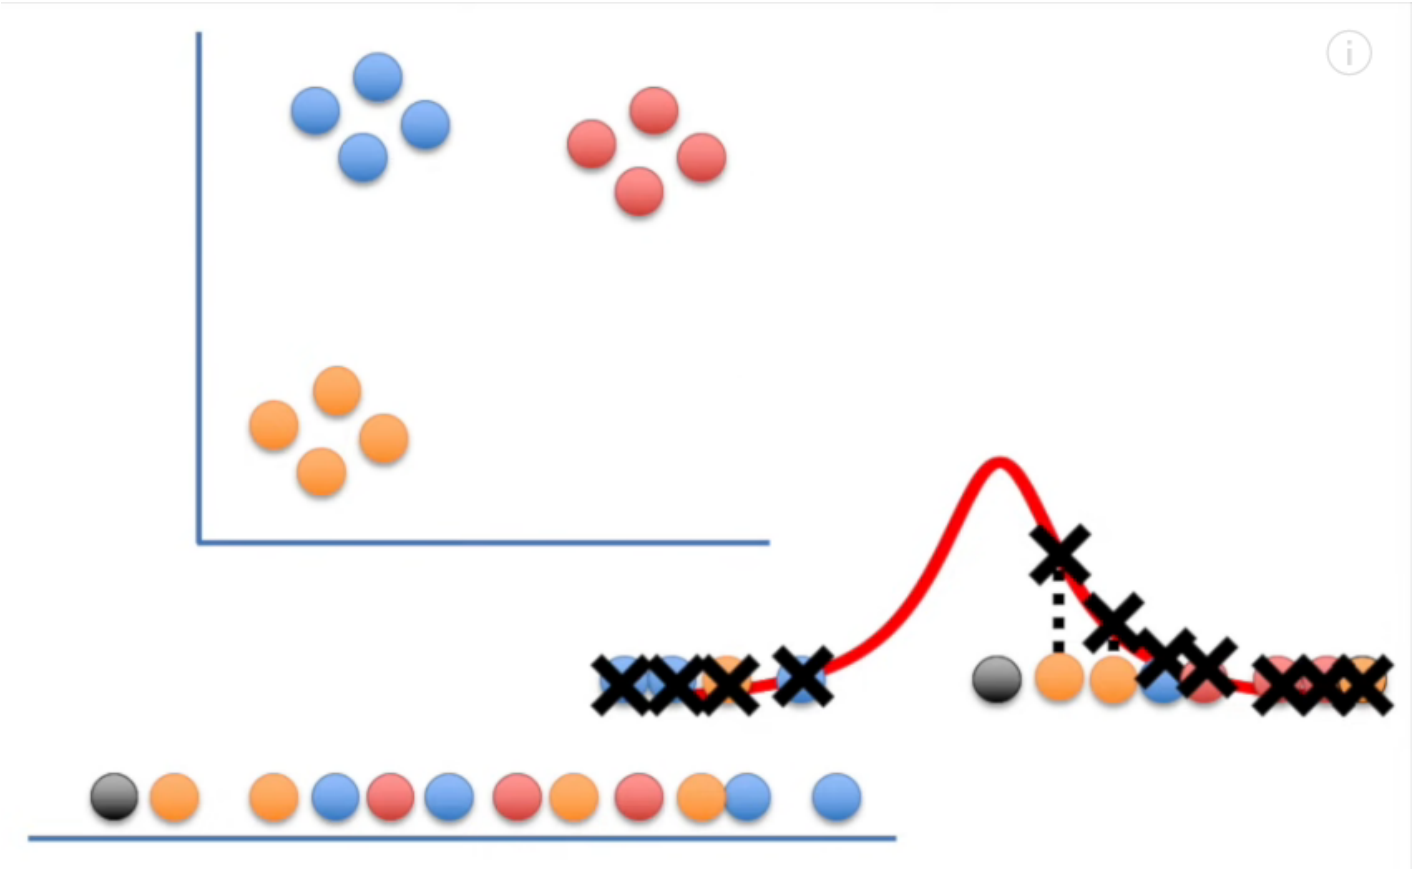

El proceso: Versión 2

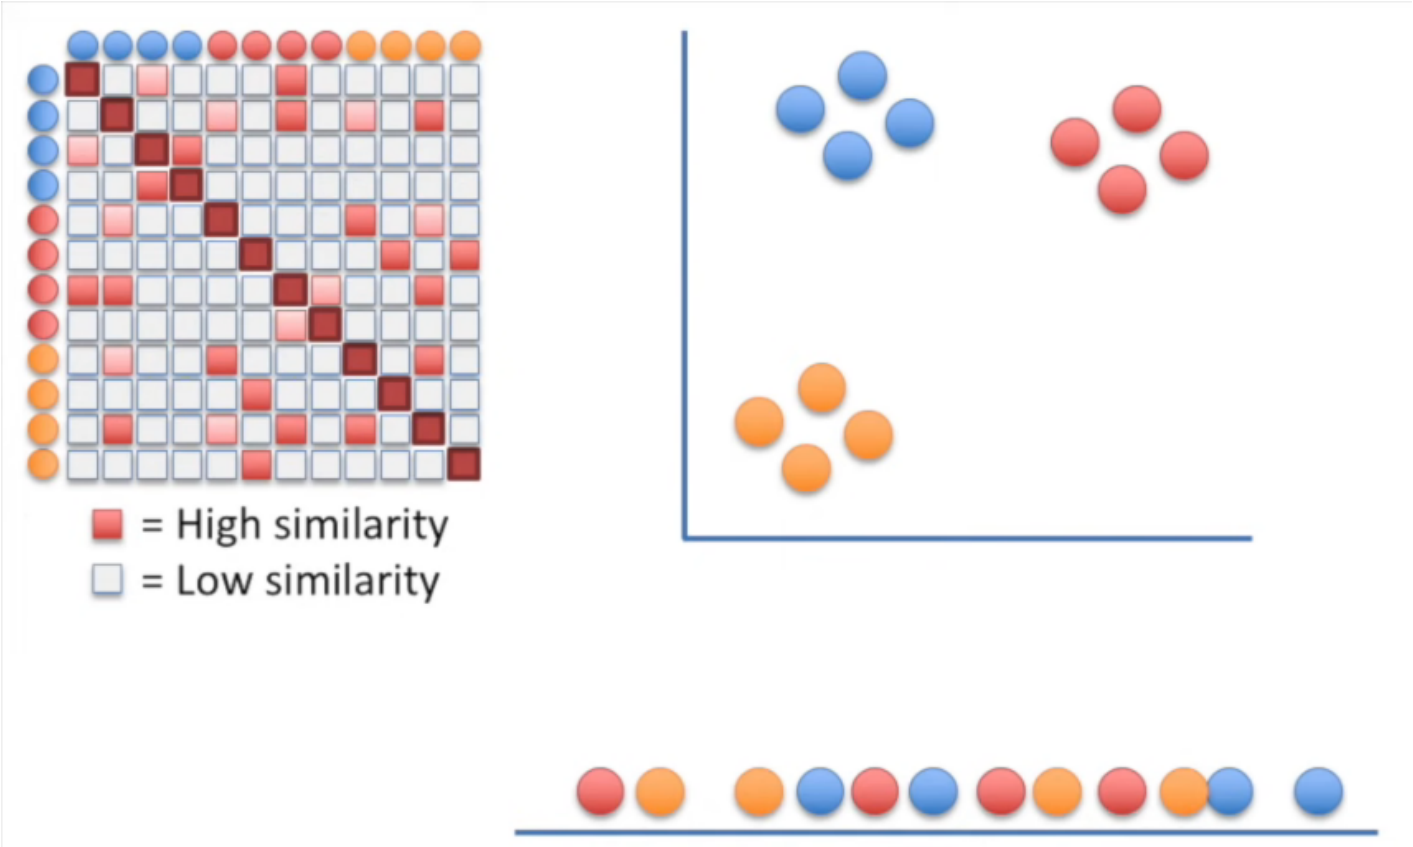

El proceso: Versión 2

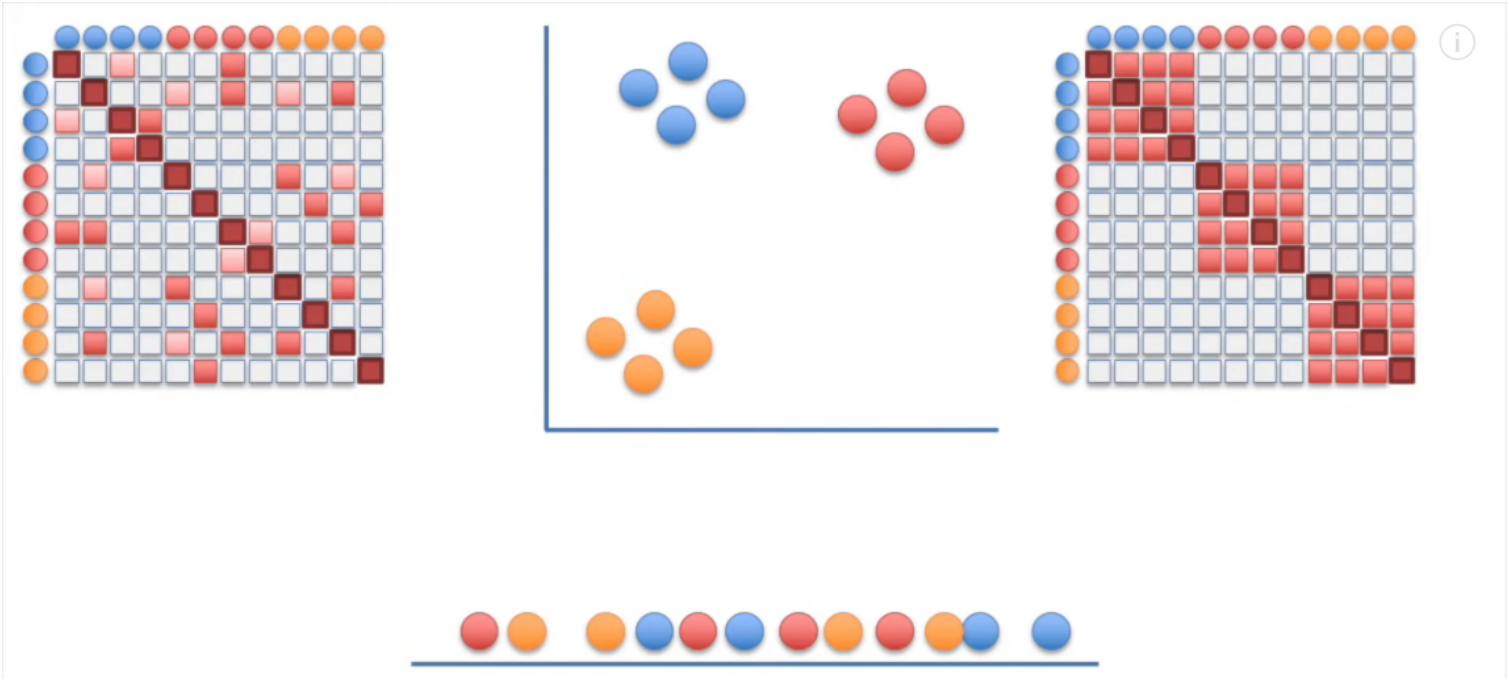

El proceso: Versión 2

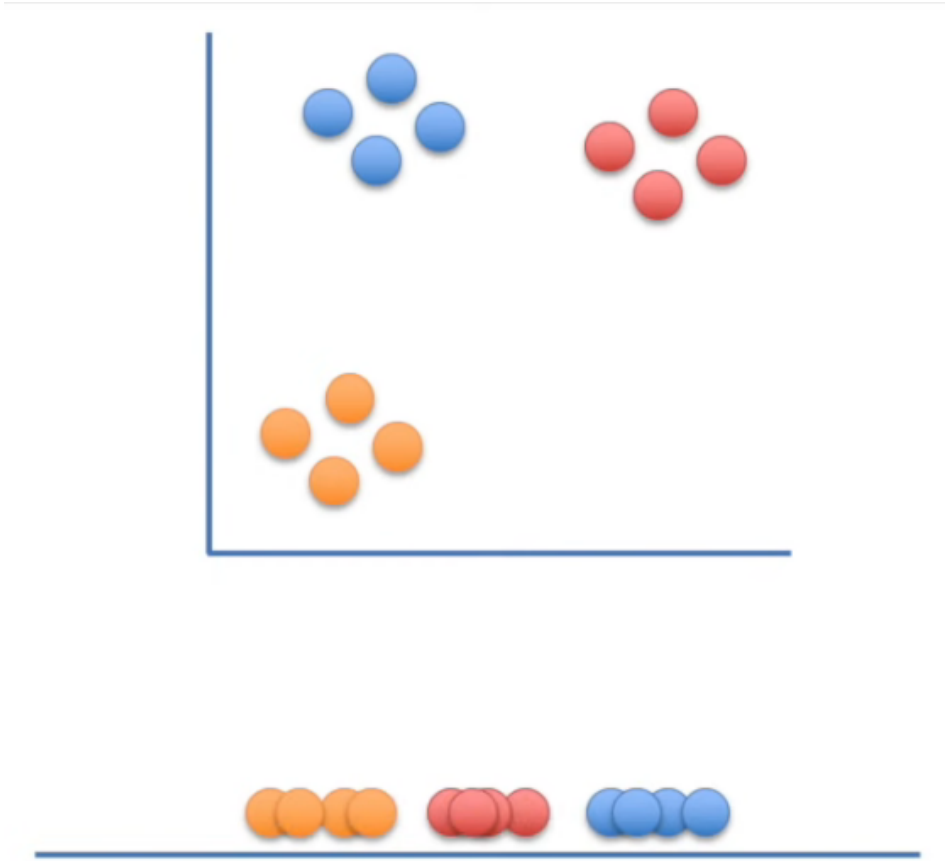

El proceso: Versión 2

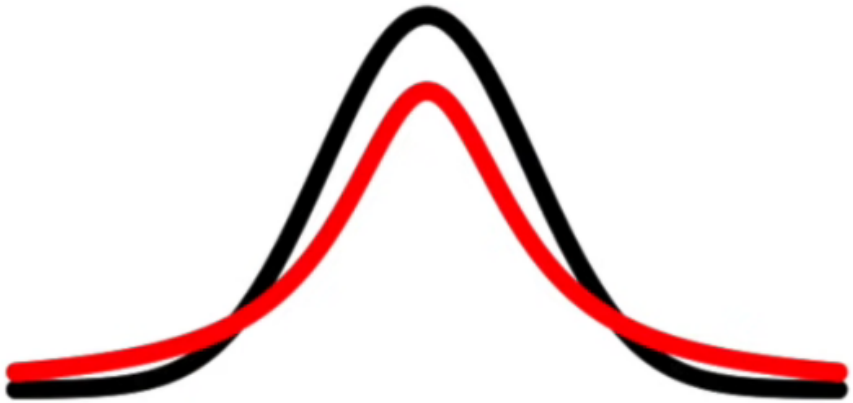

La distribución t de Student tiene como función de densidad

$$f_X(x) = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{v\pi}\,\Gamma\left(\frac{v}{2}\right)}\left(1+\frac{x^2}{v}\right)^{-\frac{v+1}{2}}$$

donde

$$\Gamma(z) = \int_0^\infty t^{z-1}e^{-t}\,dt$$

Consideraciones sobre t-SNE

- t-SNE es computacionalmente caro y relativamente lento (por ejemplo, hay que calcular las distancias entre parejas de puntos).
- Tiene la ventaja sobre PCA de funcionar bien en datos que no están relacionados linealmente.
- En general, PCA preserva la estructura global de los datos, mientras que t-SNE preserva las estructuras locales.
- Suele ser una buena opción para visualizar datos.